

# **Justificativa para a escolha do algoritmo: Redes Neurais Convolucionais (CNNs)**

A escolha do algoritmo Redes Neurais Convolucionais (CNNs) como algoritmo classificador para esse projeto se deu devido a três fatores principais: natureza dos dados, na robustez do modelo frente a problemas complexos de reconhecimento de padrões, e em evidências empíricas de seu alto desempenho em tarefas de classificação de ECGs.

## **1. Adequação à natureza dos dados de ECG**

O ECG é um sinal biomédico complexo, caracterizado por padrões morfológicos ricos (ondas P, QRS, T e U) que variam em duração, amplitude e frequência conforme diferentes condições fisiológicas e patológicas. Esses padrões contêm informações temporais e espaciais (em relação às derivações), exigindo um modelo capaz de capturar:

- Padrões locais e globais (como alterações sutis na morfologia do complexo QRS);
- Variações de tempo-frequência, o que é potencializado com o uso da Transformada de Fourier e espectrogramas como entrada da CNN;
- Relações espaciais entre derivações simultâneas, quando múltiplos canais são utilizados (exemplo: 12 derivações da PTB-XL).

CNNs são naturalmente projetadas para captar características espaciais hierárquicas e, em alguns casos, podem ser adaptadas a sinais unidimensionais (1D-CNNs) ou bidimensionais (2D-CNNs), como espectrogramas. Isso torna o algoritmo especialmente adequado para a análise automática de sinais de ECG.

## **2. Desempenho empírico em estudos recentes**

Vários estudos validam a eficácia das CNNs no diagnóstico automatizado de anomalias cardíacas, como:

- Śmigielski et al. (2021) demonstraram que CNNs aplicadas à base PTB-XL alcançaram precisão elevada na classificação de arritmias e outras anomalias, superando modelos tradicionais como KNN, SVM e Random Forest;
- Aziz et al. (2021) reforçam que CNNs são mais eficazes que algoritmos rasos, porque conseguem aprender representações profundas diretamente dos dados de ECG sem a necessidade de engenharia manual de atributos;
- Strodthoff et al. (2020) e Wagner et al. (2023), criadores da base PTB-XL, recomendam o uso de arquiteturas profundas como CNNs para lidar com a alta dimensionalidade, complexidade morfológica e multi-rotulagem dos dados.

Essas evidências empíricas demonstram que CNNs apresentam melhor acurácia, além de maior robustez e escalabilidade frente a bases de dados clínicas reais e desbalanceadas.

### 3. Integração natural com técnicas de pré-processamento

A CNN pode ser combinada de forma eficiente com a Transformada de Fourier, um requisito obrigatório desse projeto. Existem duas abordagens bem estabelecidas:

- Transformada de Fourier + Espectrograma + CNN 2D: o sinal é transformado para o domínio da frequência e convertido em uma imagem espectral, que serve como entrada para uma CNN bidimensional;
- Sinal Bruto + CNN 1D: a CNN aprende diretamente do sinal de ECG no domínio do tempo, sendo possível aplicar filtros convolucionais especializados para captar oscilações periódicas;

Essa flexibilidade favorece a experimentação de múltiplas abordagens sem a necessidade de mudanças profundas no modelo, permitindo a adaptação aos resultados experimentais e à performance dos extratores de características.

### 4. Robustez, escalabilidade e aprendizado profundo

CNNs apresentam alta capacidade de generalização, especialmente quando treinadas com regularização (como dropout, batch normalization) e com estratégias de aumento de dados (data augmentation).

Além disso, CNNs podem:

- Ser escaladas para grandes bases de dados como a PTB-XL;
- Ser integradas com frameworks como *TensorFlow* e *PyTorch* com suporte à execução em GPU;
- Ser facilmente ajustadas para tarefas multiclasse e multilabel, como é o caso do ECG, que pode conter múltiplas condições em um único exame.

## Conclusão

Dado o contexto do projeto, a natureza dos sinais de ECG, a obrigatoriedade da Transformada de Fourier, e a extensa validação científica, a escolha de Redes Neurais Convolucionais (CNNs) como algoritmo classificador é justificada como a opção mais robusta, precisa e tecnicamente apropriada. Sua integração com espectrogramas e sua eficiência em grandes volumes de dados médicos reforçam sua adequação para o objetivo de diagnóstico automatizado de anomalias cardíacas. Em comparação com alternativas como SVM, KNN ou Random Forest, as CNNs demonstram superioridade especialmente em problemas com múltiplas classes, dados de alta dimensionalidade e variabilidade morfológica, que são as características centrais do ECG clínico.